

- (10) 多诺霍 (David Donoho): 斯坦福大学统计学教授
- (11) 伯恩 (Kirk Borne): 2014 年被评为 IBM 大数据与分析英雄
- (12) 梅森 (Hilary Mason): Fast Forward Labs 发起人, 知名学者
- (13) 杨立昆 (Yann Lecun): 纽约大学数据科学中心的负责人
- (14) 哈默巴赫 (Jeff Hammerbacher): Cloudera 项目的创始人以及首席科学家
- (15) 阿钦 (Jeremy Achin): Data Robot 创始人
- (16) 扎哈里亚 (Matei Zaharia): Spark 的主要开发者, Databricks 的创始人之一
- (17) 克恩 (Gary King): 哈佛教授
- (18) 金特里 (Carla Gentry): Analytical Solution 的数据科学家
- (19) 朝乐门: 国内第一部系统阐述数据科学专著的作者, 国家精品在线开放课程“数据科学导论”的主讲人, 北京市优质教材《数据科学理论与实践》作者, 数据科学领域本体 (Data Science Ontology) 的研发者

7. 相关工具

- (1) Anaconda: 全球最受欢迎的数据科学平台之一
- (2) Jupyter Notebook: IBM 的开源、支持多种编程语言的开发工具
- (3) RapidMiner Studio: 数据科学的通用平台
- (4) Databricks: 数据科学统一分析平台
- (5) IBM Watson Studio: IBM 提供的数据科学工具
- (6) DataRobot: 自动化实现机器学习平台
- (7) Trifacta: 数据加工的工具
- (8) Paxata: 数据准备工具
- (9) Weka: 用 Java 编写的数据挖掘软件
- (10) Tableau 和 D3: 数据可视化和工具
- (11) SAS 和 SPSS: 数据分析与建模
- (12) 谷歌的 Tensorflow 与 Facebook 的 PyTorch: 深度学习框架
- (13) Open CV: 计算机视觉与图像处理

习 题

一、选择题

1. 大数据挑战主要体现在 ()。
 - A. 数据量 (Volume) 的几何级增长
 - B. 数据类型 (Variety) 的多样化
 - C. 数据价值 (Value) 的发现越来越困难
 - D. 数据处理速度 (Velocity) 要求越来越高



2. DIKW 金字塔(DIKW Pyramid)模型揭示了数据、信息、知识和 () 之间的区别与联系。

- A. 资料 B. 能源 C. 智商 D. 智慧

3. 以下四种描述中, 正确的是 ()。

- A. 大数据和海量数据是同一个事物的不同描述
B. 数据和数值是同一个事物的不同描述
C. 数据和数字是同一个事物的不同描述
D. 以上说法均不正确

4. IBM 认为, 大数据是拥有以下 4 个共同特点(又称“4V”)中任意一个的数据源: 极大的数据量级、以极快的速度移动、极广泛的数据源类型, 以及 ()。

- A. 极高的准确性 B. 极高的多样性
C. 极高的长久性 D. 极高的真实性

5. () 指从“数据视角”提出问题、在“数据层次”上分析问题、“以数据为中心”解决问题, 以及将“数据”当作决策制定的决定因素, 提高决策制定的信度与效度。

- A. 模型驱动型决策支持 B. 数据驱动型决策支持
C. 任务驱动型决策支持 D. 算法驱动型决策支持

6. 在大数据时代, 尤其在数据科学中, 人们对数据的认识与研究视角是 ()。

- A. 我能为数据做什么 B. 如何设计算法和模型
C. 数据能为我做什么 D. 如何降低计算复杂度

7. 从知识体系看, 数据科学主要以 () 为理论基础, 其主要研究内容包括数据科学基础理论、数据加工、数据计算、数据管理、数据分析和数据产品开发。

- A. 统计学 B. 机器学习
C. 数据可视化 D. (某一) 领域知识

8. 图灵奖获得者吉姆·格雷提出的科学研究的第四范式——数据密集型科学发现(Data-intensive Scientific Discovery) 描述了数据科学的 ()。

- A. 三世界原则 B. 三要素原则
C. 数据复杂性原则 D. 从简原则

9. 以下描述中错误的是 ()。

- A. 商务智能主要关注的是对“过去时间”的“解释性研究”, 主要回答的是诸如“上一个季度发生了什么?”“销量如何?”“哪里存在问题?”“在什么情况下出现的?”等问题
B. 数据科学主要关注的是对“未来时间”的“探索性研究”, 主要回答的是诸如“如果……将来会怎么样?”“最佳业务方案是什么?”等
C. 商务智能的主要处理对象以非结构化数据为主
D. 数据科学建立在数据工程之上, 属于“基于数据的处理与管理”, 主要关注的



是如何基于数据进行辅助决策 (或决策支持)、商业洞察、预测未来、发现潜在模式, 以及如何将数据转换为智慧或产品

10. () 技术支持将源代码、注释、文字、段落、图表混排在一起, 是数据科学家的常用工具之一。

- A. VizQL B. Markdown C. HTML D. Excel

11. 以下能力中, 数据科学家需要具备的能力或素质是 ()。

- A. 提出“好”的研究假设或问题, 并完成对应的试验设计
B. 喜欢团队合作与协同工作
C. 掌握数据科学的理论基础——统计学、机器学习和数据可视化
D. 学会数据科学的基础理论, 尤其是其主要理念、原则、理论和方法

12. 以下能力中, 数据工程师需要具备的能力或素质是 ()。

- A. 数据保障 B. 数据的 ETL 操作
C. 数据的备份与恢复 D. 主数据管理及数据集成

13. 以下能力中, 数据分析师需要具备的能力或素质是 ()。

- A. 良好的沟通能力 B. 应用统计学与应用机器学习
C. 数据科学 D. 一定的编程开发能力

14. 与传统科学不同的是, 数据科学是由 () 驱动, 即数据是业务、决策、战略、市场甚至组织结构变化的主要驱动因素。

- A. 目标 B. 利益 C. 数据 D. 知识

二、调研与分析题

1. 结合自己的专业领域, 调研数据科学及大数据在所属领域中的应用现状。
2. 调查分析近 3 年在数据科学领域出版的专著。
3. 调查分析数据科学家的常用方法、技术与工具。
4. 调查分析近 3 年 *The Data Science Journal* 等数据科学领域的学术期刊上发表论文的主题。
5. 调查分析近 3 年 IEEE、DSAA 等数据科学领域国际会议的主题。

